2048 游戏算法实验报告

实验对象：3×3 版 2048，目标方块 256；小组成员：同学 A、同学 B、同学 C、同学 D

摘要

本实验在完全相同的 3×3 2048 环境中比较 MCTS、完整 Expectimax、三种 TD 检查点和 PPO。每个方法使用种子 10000–10019 的 20 局自然终局，统一统计终局棋盘和、达到 256 的局数和平均步数。完整 Expectimax 的平均 sum 最高（761.0），TD 乐观 5-tuple 次之（612.1）；MCTS 的搜索预算较小，PPO 检查点的训练量不足，二者分别为 266.0 和 211.4。报告重点放在方法的决策机制、计算代价和结果差异，而不是把某一种实现单独展开。

1 实验设计与统一协议

每次移动后在空位随机生成 2（概率 0.9）或 4（概率 0.1），无合法动作时自然终局。所有方法使用相同种子集合，不设置步数上限，测试时不更新参数。终局和是棋盘九个方块之和；“通过”定义为最大方块不小于 256。训练阶段的局数或环境步数只用于说明检查点来源，不直接当作测试分数。

项目	统一设置
状态空间	3×3 棋盘，方块为 2 的幂次；目标方块 256
评测协议	每个方法 20 局，seed=10000+i，i=0…19；自然终局
指标	平均终局 sum、达到 256 的局数/比例、平均步数
实现	搜索方法在线决策；学习方法加载固定检查点并贪心执行

2 算法原理与方法差异

下表按同一层次概括六个可比较对象。TD 的共同点是用下一 afterstate 的估计值更新当前价值；其中 5-tuple 只表示特征形状，乐观初始化是探索策略，不能与 CNN 或 n-tuple 的网络结构混为一谈。

方法	核心机制	状态表示	决策与代价
MCTS	UCT 选择 + 随机出生块模拟 + 叶节点启发式	完整棋盘；树节点按局面缓存	每步重新搜索；效果随模拟次数增加，在线计算量高
完整 Expectimax	玩家动作取最大，出生块取概率期望	完整棋盘 + 对称状态表	搜索到终局；结果稳定但建表和访问代价最高
TD 乐观 5-tuple	TD(0) 更新局部特征查表值；初期高估未充分访问状态	3 张 16^5 表，24 个旋转/镜像特征	贪心查表；推理极快，依赖训练检查点质量
TD-CNN	afterstate TD + Adam 梯度更新	11 个 one-hot 平面，79,874 参数 CNN	一次批量前向；表达力强但需更多样本和训练稳定性
TD-nTuple	TD(0) 更新行、列、2×2 方格特征表	离散 n-tuple 表，使用对称规范化	查表开销小；表示能力和收敛速度介于两类 TD 之间
PPO	剪切策略目标 + GAE + 熵正则	带动作掩码的卷积残差策略网络	训练成本高、测试前向快；对奖励尺度和样本量敏感

3 训练、调参与工程优化

方法	训练/搜索预算	最终关键设置
MCTS	无训练；每步 128 次模拟	depth=12，exploration=70，rollout_random=0.15
Expectimax	无训练；完整终局搜索	depth=null，empty_weight=18，order_weight=1，target_bonus=256
TD 乐观 5-tuple	300,000 局固定检查点	width=5，optimism=300，train_seed=42
TD-CNN	50,000 局；7,512,917 个位置	Adam，lr=3e-4，batch=1024，epsilon 0.10→0.01
TD-nTuple	5,000 局	α=0.2，epsilon 0.20→0.02，target_bonus=256
PPO	检查点 50,176 env steps	64 filters，4 residual blocks，γ=0.999，λ=0.95，clip=0.2

4 测试结果与统一比较

方法	平均 sum	达到 256	平均步数
MCTS	266.0	6/20（30%）	119.45
完整 Expectimax	761.0	20/20（100%）	344.55
TD 乐观 5-tuple	612.1	20/20（100%）	277.60
TD-CNN	418.8	16/20（80%）	188.50
TD-nTuple	384.0	14/20（70%）	172.15
PPO	211.4	2/20（10%）	94.55

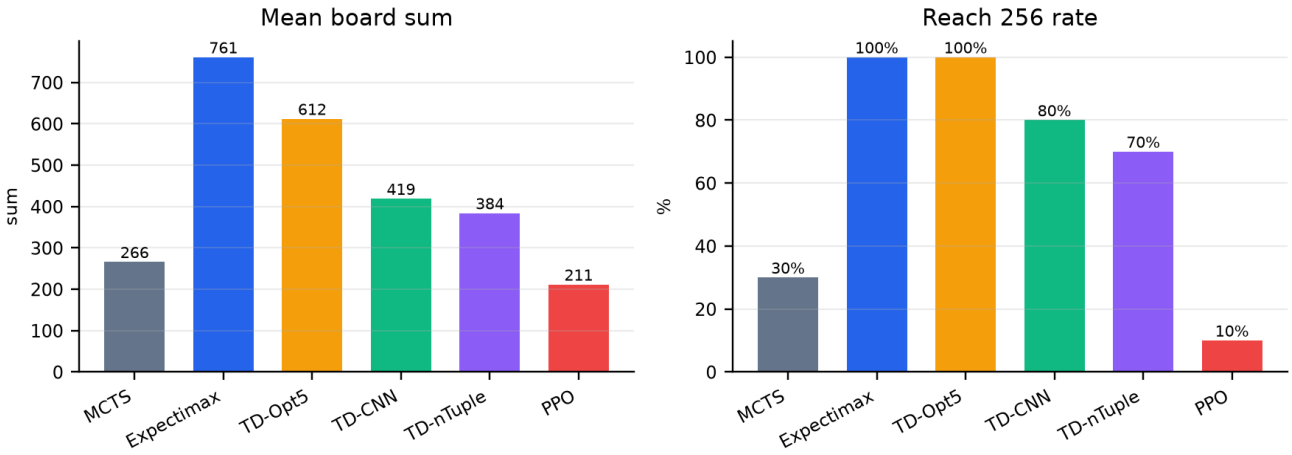


图 1 固定种子 20 局的平均终局和与 256 达成率。

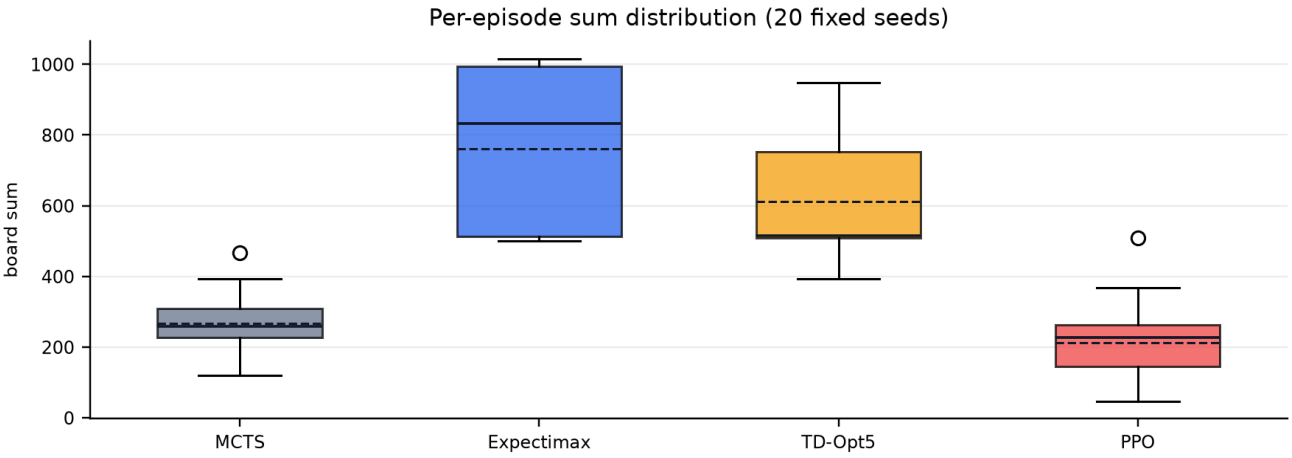


图 2 四个主要检查点的逐局终局和分布；均值线与中位数线用于观察波动。

横向比较：Expectimax 在平均 sum 和通过率上第一，但它把大量计算放在运行前的状态表和每步机会树上；TD 乐观 5-tuple 的两项指标都达到 100%/20 局，在线只需有限次查表，适合资源受限的推理场景。TD-CNN 和 TD-nTuple 都明显超过 MCTS 基线，说明 afterstate 价值学习有效，但当前训练预算仍限制了收敛。MCTS 的优势是无需训练、可直接增加搜索预算；PPO 的策略执行很快，但当前检查点在样本量和奖励设计上还没有达到前三者的稳定性。

从“效果—在线成本—训练成本”三个维度看：Expectimax 是效果优先，乐观 5-tuple TD 是在线成本优先，CNN/n-tuple TD 是学习型折中，MCTS 是无需训练的搜索基线，PPO 是适合继续扩大训练规模的策略方法。由于预算不同，不能把表中排名解释为严格的等成本优越性。

5 结论、局限、分工与复现

调参与工程优化：使用固定 20 局种子协议和单因素修改；搜索方法调预算与启发式权重，TD 调学习率、探索率和目标奖励，PPO 调 γ、GAE、裁剪范围与网络宽度。实现层面采用 D4 对称共享、afterstate、批量前向、NumPy 推理、搜索缓存、梯度裁剪和独立 RNG。

结论是：在当前 3×3 任务和固定检查点下，完整 Expectimax 得分最高；TD 乐观 5-tuple 以很低的在线计算量取得第二档效果；CNN/n-tuple TD 展示了进一步学习的空间；MCTS 和 PPO 分别受搜索预算、训练样本与奖励设置限制。下一步应使用多随机种子、统一 wall-clock/FLOPs 预算，并补充训练曲线，才能做更严格的成本公平比较。

局限：完整 Expectimax 的状态表缓存把一次性建表成本转移到离线阶段；乐观 5-tuple 检查点的原始训练入口目前不在 train.py 中；README 中的独立 500 局复测（平均 sum=639.408，463/500 达到 256）与本报告的 20 局固定协议用途不同。

小组分工（占位名）：

成员	负责内容
同学 A	环境适配、随机种子协议、基础规则和测试用例
同学 B	TD 系列、模型检查点和训练超参数
同学 C	MCTS、Expectimax、PPO 原理与搜索/策略配置
同学 D	统一评测、图表、横向分析、报告撰写与 PDF 核验

复现实验：

```
uv run python -m unittest discover -s tests -v
uv run python -m game2048.wrappers.MCTS --episodes 20 --seed 10000 --output report/data/mcts.json
uv run python -m game2048.wrappers.Expectimax --episodes 20 --seed 10000 --output
report/data/expectimax.json
uv run python -m game2048.wrappers.TD --episodes 20 --seed 10000 --output report/data/td.json
uv run python -m game2048.wrappers.ppo --episodes 20 --seed 10000 --output report/data/ppo.json
```

报告中的图表由 report/generate_report.py 根据固定评测 JSON 和仓库 README 的 TD-CNN、TD-nTuple 检查点摘要生成。