3×3 2048 自主游戏算法实验报告

蔡明辰　潘亮　陈达　孟维祎

摘要：本实验在原有 2048 代码上适配 3×3 棋盘，比较完整 Expectimax、MCTS 与乐观 5-tuple TD。三个方法分别代表完整概率搜索、有限预算采样搜索和通过交互学习价值。冻结模型与参数后，各使用 10,000 个新测试种子运行至自然终局。完整 Expectimax 的平均终局总和为 813.267，达到 256 的比例为 99.54%；乐观 TD 为 640.743 和 91.19%；MCTS 为 282.013 和 34.96%。报告结合历史参数对照，讨论对称共享、乐观初始化及计算预算的影响。

1　任务与实现

智能体通过左、右、上、下四个动作，使终局棋盘所有数字之和尽量大，并尽可能生成至少 256 的方块。有效移动后，从空格中均匀选择位置，以 0.9 和 0.1 的概率生成 2 和 4。达到 256 后继续游戏，没有合法动作时结束。

合并只改变方块分布，不增加总和；新落块才使总和增加。以 S_t 表示棋盘总和，基础奖励为 $r_t = S_{t+1} - S_t$，即新出生块的值。策略需要释放空间并避免死局，才能持续接纳新方块。

代码保留原环境的移动、合并、显示与终止逻辑，以包装类调整棋盘大小、随机源、奖励和统计信息。三个方法各自提供动作选择接口，由公共入口负责配置、权重加载和评测，避免为每个算法复制一份环境。

2　三种方法

2.1　完整 Expectimax

在玩家节点选择价值最大的合法动作，在机会节点枚举空格及出生块，按真实转移概率求期望。设 $A(s)$ 为合法动作集合，有

$$V(s) = \max_{a \in A(s)} \sum_{s'} P(s' \mid s, a) V(s'), \qquad V(s_{\text{terminal}}) = S(s) + 256\mathbf{1}\{\max(s) \geq 256\}. \tag{1}$$

算法不设置启发式深度截断，使用 C++ 求解器、棋盘编码、旋转与镜像归一以及缓存，减少重复局面。首次求解和保存价值表有较高计算与存储开销。这里的最优针对期望加权终局效用，不代表每局都能达到 256。

2.2　MCTS

每个实际动作重新建树，通过模拟估计回报。未访问动作优先扩展，已访问动作按 UCT 选择：

$$\bar{Q}(s,a) + c\sqrt{\frac{\ln(N(s)+1)}{N(s,a)}}. \tag{2}$$

$\bar{Q}$ 为模拟回报均值，N 为访问次数，c 控制探索。每次模拟按真实概率落块；达到深度上限后，以总和、空格数、蛇形排列与达标奖励评价局面，死局额外扣分。最终选择根节点平均回报最大的动作。该方法无需离线训练，但效果受模拟预算与截断估值影响。

2.3　乐观 5-tuple TD

后状态 x 表示移动后、随机落块前的棋盘。价值函数预测未来还能接纳的新方块总和。一次 TD(0) 更新的误差为

$$\delta_t = z_{t+1} + \gamma V(x_{t+1}) - V(x_t), \qquad \gamma = 1, \tag{3}$$

其中 z 为出生块的值，终局后续价值为 0。价值由 3 张 16^5 的 float32 查找表和 24 个对称特征求和得到，旋转、镜像局面共享权重 [2]。初始总价值设为 300，使访问不足的局面保留较高估计，鼓励探索 [1]。训练结束后冻结权重，直接选择后状态估值最高的合法动作。

3 评测设置与参数

三个方法各测试 10,000 局，共 30,000 局，种子为 3,000,000 至 3,009,999。该区间未用于前面的模型训练与报告评测。每局重新初始化环境；MCTS 的搜索随机数使用独立随机源，种子为环境种子加 100,000。所有对局运行至自然终局，包含未达标局，不设测试步数上限，不在达到 256 时停止。

相同种子约束随机数来源，但不同策略产生的空格不同，实际落块位置仍会不同。测试不更新 TD 权重，Expectimax 复用同一求解缓存。表1给出所用配置。

表 1　所用参数与计算预算

方法	配置
完整 Expectimax	搜索至终局，终局达标奖励 256，复用价值表
MCTS	每步 128 次模拟，深度 12，$c = 70$；模拟随机动作比例 0.15，空格权重 18
乐观 5-tuple TD	训练 300,000 局，训练种子 42，初始总价值 300；前 70% 训练 $\alpha = 0.1$，之后 0.03；前 80% 训练 $\epsilon = 0.02$，之后 0.002

为完成大批量评测，MCTS 采用独立的 C++ 加速内核，保留原来的规则、启发式、动作顺序和 Python 随机流。评测前核对了 194 个随机棋盘的动作与随机状态、3 局完整对局的 322 次动作，以及 10,000 组随机原语；均与原实现一致。真实对局仍调用原环境，TD 与 Expectimax 沿用原推理入口。逐局记录及汇总随材料保留。

3.1 简要超参数讨论

表2来自历史 TD 对照，各从头训练 10 万局，使用相同训练种子 42 和 500 局测试种子 20000 至 20499，学习率、探索率日程一致。它与本次万局榜单分别统计。

表 2　历史 TD 参数对照

TD 配置	平均终局总和	达到 256
不共享对称，初值 0	417.688	72.2%
共享对称，初值 0	605.764	89.0%
共享对称，初值 300	540.784	94.4%

对称共享使相似局面复用经验，本轮总和与达标率均提高。初值 300 提高了达标率，却使总和下降约 65，说明达标和继续累积总和存在取舍。这里只比较 0 和 300，不能认定 300 最优。学习率与探索率随训练进度一起变化，尚不足以独立确认各自的最佳取值；MCTS 也缺少模拟次数、深度与探索系数的逐项多取值实验。

4 实验结果

表3列出新测试结果。总和均值 95% 区间使用正态近似，达标率区间使用 Wilson 方法；二者均只反映冻结模型的评测抽样波动，不包含重复训练的差异。

完整 Expectimax 平均总和最高，比 TD 高 172.524，约 26.9%；同时有 46 局未达到 256，说明按期望效用搜索并不能逐局保证成功。其 10,000 局中有 7,245 局的最大块为 512，129 局为 1024。乐观 TD 有 9,119 局达到 256，5,498 局达到 512。此前 20 局全达标是有限样本现象，不能视为真实成功率 100%。

MCTS 平均总和为 282.013，达标 3,496 局，在当前 128 次模拟与深度 12 的配置下仍落后。小棋盘死局敏感，有限深度与启发式可能使短期收益估计偏离长期收益，但具体原因需要额外控制搜索预算后确认。平均步数与总和的排序一致，因为存活更久通常可以接纳更多新方块。

表 3　每方法 10,000 局的评测结果

方法	平均总和	达到 256	平均步数
完整 Expectimax	813.267	9954/10,000（99.54%）	367.68
乐观 5-tuple TD	640.743	9119/10,000（91.19%）	289.22
MCTS	282.013	3496/10,000（34.96%）	126.15

表 4　测试结果的 95% 置信区间

方法	总和均值区间	达标率区间
Expectimax	809.07–817.46	99.39%–99.65%
TD	636.45–645.03	90.62%–91.73%
MCTS	280.29–283.73	34.03%–35.90%

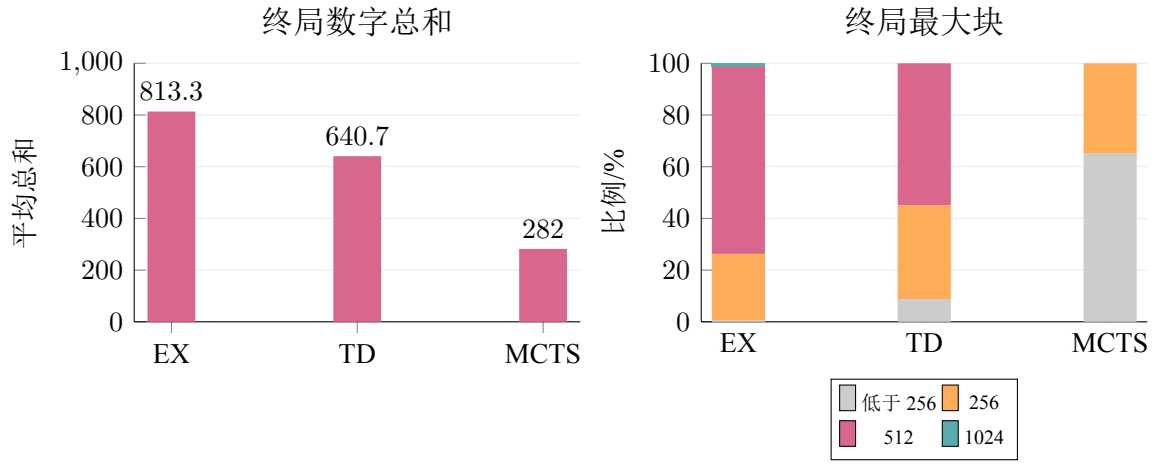


图 1　平均终局总和与终局最大块分布，各方法均为 10,000 局。

本次统一了环境、测试样本、终止条件与统计指标，未统一训练、建表与每步搜索资源。三个方法内部的优化目标也有差别：完整搜索使用终局总和与达标加奖，TD 学习未来总和增量，MCTS 使用截断启发式。因此结果描述当前配置的表现，不把差异全部归因于算法类别。并行评测和加速内核的运行时间不作为方法速度排名。

5　结论与分工

在本次 10,000 局测试中，完整 Expectimax 获得最高平均总和和达标率；乐观 5-tuple TD 通过离线训练换取查表决策；MCTS 无需离线训练，但当前搜索预算下效果仍有限。后续应在共同目标下明确训练与推理时限，用多个训练种子检验参数影响。

成员	负责内容
蔡明辰	环境适配、随机种子与规则核对，统筹代码整合
潘亮	TD 方法实现、模型训练与超参数讨论
陈达	MCTS 与 Expectimax 实现、评测及对照分析
孟维祎	评测数据整理、图表制作与报告撰写

参考文献

[1] Guei H, Chen L-P, Wu I-C. Optimistic Temporal Difference Learning for 2048. 2021.
[2] Szubert M, Jaskowski W. Temporal Difference Learning of N-Tuple Networks for the Game 2048. CIG, 2014.