

3×3 2048 自主游戏

强化学习课程实验汇报

蔡明辰、潘亮、陈达、孟维祎



南開大學
Nankai University

任务与环境

目标：终局总和尽量大，并生成至少 256 的方块

达到 256 后继续游戏。每次有效移动后，以 0.9/0.1 概率落下 2/4。

移动前

2	2	
4		

总和 8

向左合并后

4		
4		

总和 8

随机落块示例

4		
4		
		2

总和 10

合并保持总和，随机落块增加总和。释放空间才能继续接纳新方块。

相同的 20 个测试种子，冻结参数，运行至自然终局。



完整 Expectimax：先看完整搜索

玩家节点选最佳动作，机会节点按真实概率加权，一直递推到终局。

$$Q(s,a)=\sum_{s'}P(s'\mid s,a)V(s'),\qquad V(s)=\max_{a\in A(s)}Q(s,a)$$

s 为当前棋盘，s' 为动作与落块后的棋盘。

$A(s)$ 为合法动作集合，P 为转移概率。

终局边界：$V(s)=U(s)$，$S(s)$ 为总和

$$U(s)=S(s)+256\cdot\mathbf{1}_{\{\max(s)\geq 256\}}$$

移动后有 2 个空格时

位置	出现 2	出现 4
空格 1	0.45	0.05
空格 2	0.45	0.05

各分支概率相加为 1。

C++ 求解器，旋转/镜像归一与缓存。首次求解及存储开销较大。



MCTS：用采样减少搜索开销

每次决策 128 次模拟，搜索深度 12，探索系数 70

未访问动作优先扩展。已访问动作按 UCT 选择：

$$\mathrm{UCT}(s,a) = \underbrace{\bar{Q}(s,a)}_{\text{模拟均值}} + \underbrace{c\sqrt{\frac{\ln(N(s)+1)}{N(s,a)}}}_{\text{探索项}}$$

$\bar{Q}$：该动作的模拟回报均值

$N(s)$：父节点访问次数

$N(s,a)$：动作访问次数，c 控制探索

模拟预算决定估计精度，截断估值会影响决策。

每步重新建树，按真实概率模拟落块

到达深度上限后，用启发式评价局面

最终选择根节点平均回报最大的动作



TD：从后状态学习长期价值

后状态 x_t：移动后、随机落块前的棋盘。以乐观 TD 为例：

$$\delta_t = \underbrace{z_{t+1} + \gamma V(x_{t+1})}_{\text{更新目标}} - \underbrace{V(x_t)}_{\text{当前估值}}$$

z_{t+1} 为新落块数值 2 或 4，$\gamma = 1$，终局之后的后续价值取 0。

用 TD 误差修正当前估值，学习未来可接纳的新方块总和。

价值表示	实现特点
乐观 5-tuple	3 张 16^5 表，24 个对称特征，初始总价值 300
CNN-TD	11 通道棋盘编码，卷积价值网络
普通 n-tuple	行、列和 2×2 局部模式，含启发式先验

乐观初始化鼓励尝试较少访问的局面。其余 TD 版本的效用定义有所不同。

PPO：直接学习动作策略

卷积残差网络提取棋盘特征

策略分支

输出四个方向的概率

屏蔽非法动作并重新归一

测试选择概率最大的合法动作

价值分支

估计状态价值

与轨迹回报共同用于 GAE 优势估计

剪切目标限制单次策略更新幅度

训练循环：收集交互轨迹，计算优势，再更新网络。

剪切系数 0.2，折扣因子 0.999，GAE 参数 0.95。

当前模型的训练量和奖励设置仍需进一步检验。



实现与超参数

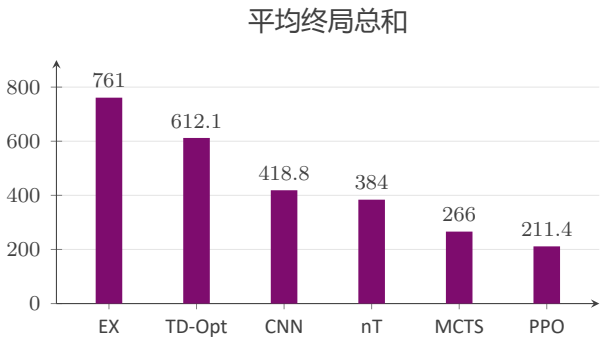
继承原环境，共用配置与评测入口。

方法	计算预算	关键设置
Expectimax	完整搜索与缓存	终局达标奖励 256
MCTS	每步 128 次模拟	深度 12，$c = 70$
乐观 TD	300,000 局	初始总价值 300
CNN-TD	50,000 局	学习率 3×10^{-4}，批量 1024
n-tuple TD	5,000 局	$\alpha = 0.2$，探索率 0.20 降至 0.02
PPO	50,176 个 RL 环境步	$\gamma = 0.999$，clip=0.2

搜索预算影响前瞻精度，学习率与探索率影响更新和覆盖。

训练局数、RL 步数和搜索次数不能直接等同，PPO 另有预训练记录。

实验结果



方法	达到 256
Expectimax	20/20
乐观 TD	20/20
CNN-TD	16/20
n-tuple TD	14/20
MCTS	6/20
PPO	2/20

完整搜索平均总和比乐观 TD 高 **24.3%**。

每方法 20 局。CNN 与普通 n-tuple 仅有汇总值，训练与搜索预算不同。

结果解释与实验局限

当前设置下，完整搜索与乐观 TD 效果较好

已统一环境规则、测试种子和终止条件。

训练与搜索资源尚未统一，不能据此比较等资源下的算法优劣。

每方法仅 20 局，CNN 与普通 n-tuple 只有汇总结果。

后续固定运行时间，并用多个训练种子重复实验。



结论

完整 Expectimax 取得最高平均总和。

乐观 TD 兼顾效果与在线计算开销。

谢谢，欢迎提问。

完整测试结果

方法	平均总和	达到 256	平均步数
完整 Expectimax	761.00	20/20	344.55
乐观 5-tuple TD	612.10	20/20	277.60
CNN-TD	418.80	16/20	188.50
n-tuple TD	384.00	14/20	172.15
MCTS	266.00	6/20	119.45
PPO	211.40	2/20	94.55

乐观 TD 另一次 500 局测试：平均 639.408，463 局达标。

该次测试设置不同，不与上表合并。

分工与参考文献

蔡明辰	环境适配、规则测试与代码整合
潘亮	TD 方法、模型训练与超参数整理
陈达	搜索方法、PPO 与对照分析
孟维祎	评测整理、图表与报告

[1] Guei et al. Optimistic Temporal Difference Learning for 2048, 2021.

[2] Szubert & Jaskowski. N-Tuple Networks for the Game 2048, CIG 2014.

[3] Schulman et al. Proximal Policy Optimization Algorithms, 2017.