

3×3 2048 自主游戏

强化学习课程实验汇报

蔡明辰、潘亮、陈达、孟维祎



南開大學
Nankai University

任务与环境

目标：终局总和尽量大，并生成至少 256 的方块

达到 256 后继续游戏；有效移动后，以 0.9/0.1 概率落下 2/4。

移动前

2	2	
4		

总和 8

向左合并后

4		
4		

总和 8

随机落块示例

4		
4		
		2

总和 10

合并保持总和，随机落块增加总和。每方法 10,000 局，运行至自然终局。



完整 Expectimax：按概率搜索至终局

玩家节点选最佳动作，机会节点按真实概率加权，一直递推到终局。

$$Q(s,a)=\sum_{s'}P(s'\mid s,a)V(s'),\qquad V(s)=\max_{a\in A(s)}Q(s,a)$$

s 为当前棋盘，s' 为动作与落块后的棋盘。

$A(s)$ 为合法动作集合，P 为转移概率。

终局边界 $V(s)=U(s)$，$S(s)$ 为总和

$$U(s)=S(s)+256\cdot\mathbf{1}_{\{\max(s)\geq 256\}}$$

移动后有 2 个空格时

位置	出现 2	出现 4
空格 1	0.45	0.05
空格 2	0.45	0.05

各分支概率相加为 1。

C++ 求解器，旋转/镜像归一与缓存。首次求解及存储开销较大。



MCTS：通过模拟估计动作价值

每次决策 128 次模拟，搜索深度 12，探索系数 70

未访问动作优先扩展。已访问动作按 UCT 选择：

$$\mathrm{UCT}(s,a) = \underbrace{\bar{Q}(s,a)}_{\text{模拟均值}} + \underbrace{c\sqrt{\frac{\ln(N(s)+1)}{N(s,a)}}}_{\text{探索项}}$$

$\bar{Q}$：动作的模拟回报均值

$N(s)$：父节点访问次数

$N(s,a)$：动作访问次数，c 控制探索

每步重新建树，按真实概率模拟落块

深度截断后，用启发式评价局面

最终选择根节点平均回报最大的动作



TD：学习后状态的长期价值

后状态 x_t：移动后、随机落块前的棋盘

$$\delta_t = \underbrace{z_{t+1} + \gamma V(x_{t+1})}_{\text{更新目标}} - \underbrace{V(x_t)}_{\text{当前估值}}$$

z 为新落块 2 或 4，$\gamma = 1$，终局之后的后续价值取 0。

价值表示

3 张 16^5 查找表，24 个对称特征

旋转与镜像局面共享权重

训练与决策

训练 300,000 局，初始总价值 300

测试时比较合法动作的后状态估值

实现与评测协议

每种方法 10,000 局，共 30,000 局，全部运行至自然终局

共同条件	设置
环境	3×3 棋盘；落块 2/4 的概率为 0.9/0.1
测试种子	3,000,000 至 3,009,999，每局重新设置种子
决策设置	MCTS 每步 128 次模拟，深度 12，$c = 70$
训练与缓存	冻结 TD 权重，Expectimax 复用完整求解缓存

环境与搜索随机数分开，达到 256 后继续游戏。

统一评测样本，不等于统一训练与搜索计算量。



超参数讨论

TD 历史对照：同为 10 万局训练，500 局测试

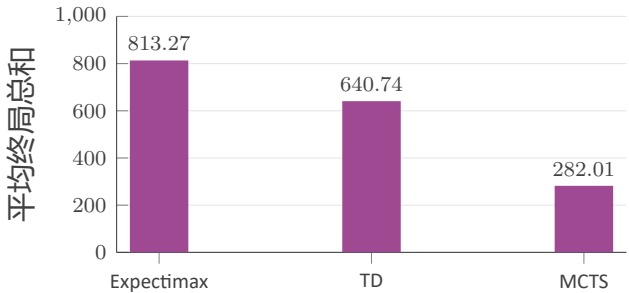
TD 配置	平均总和	达到 256
不共享对称，初值 0	417.7	72.2%
共享对称，初值 0	605.8	89.0%
共享对称，初值 300	540.8	94.4%

对称共享提高经验利用率；乐观初值提高达标率，但总和下降。

α：0.1 降至 0.03；ϵ：0.02 降至 0.002。尚无独立多取值对照。

历史对照与本次万局榜单分别统计，不把采用参数称为最优值。

每方法 10,000 局的实验结果



方法	达标局数	达标率
Expectimax	9954	99.54%
TD	9119	91.19%
MCTS	3496	34.96%

完整搜索总和最高；乐观 TD 次之；有限预算 MCTS 仍有明显差距。

每方法 10,000 局，包含全部失败局；置信区间与分布见备用页。

结论

完整搜索、采样搜索与学习估值各有计算代价

完整 Expectimax：本次平均总和最高，首次建表和存储开销较大。

乐观 5-tuple TD：离线学习后查表决策，测试达标率 91.19%。

MCTS：无需离线训练，当前 128 次模拟的效果仍有提升空间。

谢谢大家

补充：区间与最大块分布

方法	总和均值 95% 区间	达标率 95% 区间
Expectimax	809.07–817.46	99.39%–99.65%
TD	636.45–645.03	90.62%–91.73%
MCTS	280.29–283.73	34.03%–35.90%

方法	低于 256	256	512	1024	平均步数
Expectimax	46	2580	7245	129	367.68
TD	881	3621	5498	0	289.22
MCTS	6504	3494	2	0	126.15

总和区间采用均值正态近似，达标率采用 Wilson 区间。仅反映评测波动。

问答备用

补充：分工与问答

成员	工作分工
蔡明辰	环境适配、规则核对与代码整合
潘亮	TD 实现、训练及超参数讨论
陈达	MCTS 与 Expectimax 实现及结果分析
孟维祎	评测整理、图表与汇报材料

为什么 1 万局仍不能证明等资源下算法更优?

它减少评测抽样波动，但没有统一训练量、建表成本与每步计算量。

完整 Expectimax 属于已知模型规划；TD 通过交互学习权重。

问答备用