3×3 2048 自主游戏汇报讲稿

正文 10 页，共 5 分钟。第 11、12 页为问答备用。

第 1 页 3×3 2048 自主游戏（0:00–0:10）

大家好，我们介绍 3 乘 3 的 2048 自主游戏，重点比较搜索方法和强化学习方法的实现与结果。

第 2 页任务与环境（0:10–0:40）

目标是让终局棋盘总和尽量大，同时生成至少 256 的方块。看下面这个例子：两个 2 合成 4，总和仍是 8，随机落下一个 2 后，总和才变成 10。所以提高总和，需要不断释放空间来接纳新方块。测试时，达到 256 后继续游戏，直到没有合法动作，各方法使用同一组 20 个测试种子。

第 3 页完整 Expectimax：先看完整搜索（0:40–1:25）

先讲完整 Expectimax，它把规则已知的搜索问题算到终局。在玩家节点，选择期望效用最大的合法动作；在机会节点，按实际落块概率加权。比如移动后有两个空格，每个位置出现 2 的概率是零点四五，出现 4 的概率是零点零五。终局效用是棋盘总和，再加 256 的达标奖励。这里的最优针对这项期望效用，不是优先最大化达标概率。实现采用 C 加加求解器，用旋转、镜像归一和缓存减少重复局面，代价是首次求解和存储开销较大。

第 4 页 MCTS：用采样减少搜索开销（1:25–2:00）

完整枚举的开销较大，MCTS 改为采样。每次实际决策重新建树，做 128 次模拟，最多前看 12 步。未访问动作优先扩展；已访问动作使用下面的 UCT 公式。左边是模拟回报的均值，右边是探索项，访问较少的动作得到更大的探索奖励。代码里对父节点访问次数使用加一再取对数。模拟按真实概率落块，深度截断后用启发式估值，最后选择根节点平均回报最大的动作。

第 5 页 TD：从后状态学习长期价值（2:00–2:45）

TD 通过训练复用过去的经验。这里用移动后、随机落块前的后状态表示动作结果。以乐观 TD 为例，价值估计未来还能接纳多少新方块。公式把下一次落块的数值，加上下一后状态的价值，作为更新目标，再减去当前估值。终局之后的后续价值取零，折扣因子取一。乐观 5 元组将局部棋盘编码成查表特征，用三张表共享 24 个对称特征，初始总价值设为 300。较少访问的局面保持较高估值，能够鼓励探索。我们还比较了 CNN 和普通元组表，但它们的效用定义有所不同。

第 6 页 PPO：直接学习动作策略（2:45–3:20）

PPO 直接输出四个方向的动作概率。卷积残差网络提取棋盘特征，策略分支给出动作概率，价值分支用于估计优势。训练时先收集交互轨迹，再用 GAE 计算优势，并用剪切目标限制策略更新幅度，这里的剪切系数是零点二。网络在输出端屏蔽非法动作，测试时选择概率最大的合法动作。本次模型表现有限，还需要进一步检验训练量和奖励设置。

第 7 页实现与超参数（3:20–3:50）

这些方法共用环境和评测入口。表中列出实际模型的训练量和搜索预算，不能把训练局数、环境步数和模拟次数直接等同，PPO 还有教师预训练记录。超参数上，搜索预算影响前瞻精度，TD 学习率和探索率影响更新与覆盖，PPO 剪切系数控制更新幅度。本次没有做单因素消融，因此不能把这些值称为最优参数。

第 8 页实验结果（3:50–4:35）

结果按平均终局总和排序。完整 Expectimax 为 761，乐观 TD 为 612.1，两者在 20 局里都达到 256。完整搜索比乐观 TD 高大约百分之二十四。CNN 和普通元组表的平均总和分别为 418.8 和 384，达标次数分别为 16 次和 14 次。当前 MCTS 为 266，PPO 为 211.4。这说明完整搜索和乐观查表 TD 在当前设置下效果较好。但训练和搜索资源没有统一，CNN 与普通元组表也只有汇总结果，所以这个榜单不能用来证明等资源下的算法优劣。

第 9 页结果解释与实验局限（4:35–4:50）

目前统一了环境规则、测试种子和终止条件，但计算资源尚未统一，20 局也只是有限样本。下一步应固定运行时间，并用多个训练种子重复实验。

第 10 页结论（4:50–5:00）

本次完整 Expectimax 效果最好，乐观 TD 的在线决策开销较小。我们的汇报到这里，谢谢大家。

问答准备（1–2 分钟）

根据现场问题选择回答，不必逐项宣读。

合并不增加总和，为什么这个目标有意义？

总和衡量游戏吸纳新方块的能力。要持续吸纳出生块，策略必须通过合并释放空间并避免死局。它与常见的合并得分不是同一个指标。

Expectimax 算强化学习吗？

完整 Expectimax 是利用已知环境模型的规划算法，不需要从交互中学习权重。这里用它作为对照，TD 和 PPO 属于学习方法。

为什么乐观初始化可以帮助 TD？

未充分访问的状态保留较高估值，智能体更愿意尝试这些状态。随着回报更新，估值逐渐下降。初值太高也可能延缓收敛，300 只是本模型设置，并非消融确认的最优值。

训练轮数是否一样，排名公平吗？

不一样。统一的是环境规则、20 个测试种子和终止条件，训练局数、PPO 环境步数和搜索开销没有统一。这个榜单比较现有实现，不能据此证明某个算法在等资源下更优。

PPO 为什么低，是否说明它不适合？

当前数据只能说明这个模型表现有限。训练样本量、奖励尺度、教师预训练与优化稳定性都可能影响结果，需要重复训练和单因素对照。

完整搜索的最优是对什么目标？

玩家节点最大化终局总和加 256 倍达标指示的期望值。它没有把达标概率作为第一优先级，也没有优先在生成 256 时结束游戏。

怎么继续研究超参数？

先固定共同目标与时间预算，再分别调整 MCTS 模拟次数、TD 学习率和探索率等单一因素。每个设置重复多个训练种子，最后用新的测试种子评价。